

Resultado 1: Proyecto 2 – Analítica de Resultados Saber 11

Modelos predictivos pruebas Saber 11 para la Secretaría de Educación del Atlántico

Isabella Caputi (202122075) - Rol: Ciencia de datos, Análisis de negocio, Tablero de datos

Sofía Vásquez (202123910) - Rol: Ciencia de datos, Análisis de negocio, Tablero de datos

María Paula Ospina (202123208) - Rol: Ciencia de datos, Análisis de negocio, Despliegue y mantenimiento

Comprensión de negocio y datos

Usuario Final Seleccionado

El producto desarrollado está dirigido a la **Secretaría de Educación del Departamento del Atlántico**, aquella responsable de la planificación y seguimiento de la política educativa a nivel de departamentos. Esta institución es la encargada de asignar recursos, diseñar programas de mejora académica y monitorear indicadores de calidad educativa. Dado que el conjunto de datos analizado corresponde al departamento del Atlántico, esta entidad actúa como el usuario más pertinente del producto, ya que requiere evidencia cuantitativa para orientar decisiones y reducir brechas educativas.

Resumen ejecutivo de los hallazgos principales

Los resultados principales muestran que los tres modelos aportan información complementaria para la Secretaría de Educación del Atlántico. Los modelos de clasificación familiar y de colegio permiten estimar la probabilidad de que un estudiante alcance alto desempeño, definido como un puntaje global igual o superior a 300. El modelo familiar obtuvo un AUC ROC de **0.7687**, precisión de **0.673**, recall de **0.1965** y F1 de **0.3042**, mientras que el modelo de colegio obtuvo un AUC ROC de **0.7685**, precisión de **0.4854**, recall de **0.4812** y F1 de **0.4833**. Esto indica que ambos modelos tienen una capacidad similar para distinguir entre estudiantes de alto y bajo desempeño, aunque el modelo familiar es más preciso cuando predice alto desempeño y el modelo de colegio logra un mejor balance entre precisión, recall y F1. Los modelos usan redes neuronales para clasificación binaria.

El modelo general de regresión complementa los modelos anteriores al estimar directamente el puntaje global esperado del estudiante, combinando variables familiares, tecnológicas e institucionales. Este modelo obtuvo un **RMSE de 41.787**, **MAE de 33.545** y **R² de 0.3472**, lo que significa que sus predicciones tienen un error promedio aproximado de 33.5 puntos y explican cerca del 34.7% de la variabilidad del puntaje global. En conjunto, los resultados evidencian que el desempeño académico depende de múltiples dimensiones: condiciones familiares, recursos del hogar y características institucionales del colegio. Por esta razón, el tablero no debe interpretarse como una herramienta de predicción exacta individual, sino como un producto analítico para identificar patrones, comparar perfiles de riesgo y apoyar decisiones de focalización de recursos educativos.

Pregunta de Negocio 1

El desempeño académico en las pruebas Saber 11 no depende únicamente de las capacidades individuales de los estudiantes, sino también de las características institucionales de los colegios donde realizan su proceso educativo. Aspectos como la jornada académica, el bilingüismo y la naturaleza de la institución pueden influir en las oportunidades de aprendizaje y, en consecuencia, en los resultados obtenidos.

¿Es posible predecir si un estudiante del Atlántico, a partir de las características institucionales de su colegio, alcanzará un puntaje global alto en las pruebas Saber 11?

Relevancia para el Usuario

Responder esta pregunta permite identificar qué tipos de instituciones educativas presentan mayores probabilidades de asociarse con mejores resultados académicos. Para la Secretaría de Educación del Atlántico, este análisis resulta útil para reconocer patrones institucionales relacionados con el desempeño estudiantil y apoyar decisiones orientadas al fortalecimiento de la calidad educativa y la asignación de recursos.

Análisis de Datos

El análisis se realizó utilizando únicamente variables institucionales del colegio. Las variables seleccionadas fueron: naturaleza del colegio, bilingüismo, jornada, calendario académico, área de ubicación, carácter institucional y género del colegio. Durante la exploración inicial se evidenció que estas variables contaban con buena calidad de datos y suficiente variabilidad para el modelamiento. Posteriormente, se aplicó un proceso de limpieza y transformación que incluyó normalización de categorías y codificación One-Hot Encoding para convertir las variables categóricas en variables numéricas aptas para el entrenamiento del modelo. El análisis descriptivo permitió identificar asociaciones moderadas entre algunas variables institucionales y el puntaje global. Variables como jornada completa, calendario B y colegios bilingües presentaron relaciones positivas con el desempeño académico, mientras que la jornada nocturna mostró una relación negativa. Estos resultados sugieren que las condiciones institucionales aportan información relevante sobre el rendimiento estudiantil.

Modelo Implementado

Para resolver esta pregunta se implementó un modelo de clasificación binaria basado en una red neuronal multicapa utilizando TensorFlow y Keras. La variable objetivo correspondió a si el estudiante alcanzó o no un puntaje global alto en las pruebas Saber 11, considerando como alto desempeño puntajes iguales o superiores a 300 puntos. A través de Grid Search se evaluaron diferentes configuraciones de hiperparámetros, variando número de neuronas, learning rates, tasas de Dropout y pesos de clase. El modelo final estuvo compuesto por tres capas densas de 96, 48 y 24 neuronas con funciones de activación LeakyReLU, acompañadas de Batch Normalization y Dropout para reducir el riesgo de sobreajuste. Además, se utilizó una capa de salida sigmoide y el optimizador Adam con learning rate de 0.001. Los resultados muestran un Accuracy cercano al 80% y un ROC-AUC aproximado de 0.74, indicando que el modelo logra diferenciar razonablemente entre estudiantes de alto y bajo desempeño utilizando únicamente variables institucionales.

Hallazgos Asociados

Los resultados evidenciaron que las variables institucionales sí contienen información relevante para diferenciar estudiantes con alto y bajo desempeño en las pruebas. A partir del análisis de correlaciones y del modelo, variables como la jornada académica, el bilingüismo, el calendario escolar y la naturaleza del colegio mostraron mayor relación con el puntaje global. Además, las métricas obtenidas, indican que existe una capacidad predictiva moderada utilizando únicamente variables institucionales del colegio.

Las métricas del modelo indican que las variables institucionales aportan capacidad predictiva para identificar estudiantes con alto desempeño. Sin embargo, su desempeño también sugiere que estas variables no explican por completo el rendimiento académico, ya que este depende de múltiples factores familiares, socioeconómicos e individuales.

Pregunta de Negocio 2

Predecir si un estudiante puede alcanzar un puntaje global alto en Saber 11 permite identificar patrones asociados al buen desempeño y reconocer qué características pueden estar relacionadas con mejores resultados académicos.

¿Es posible predecir si un estudiante del Atlántico obtendrá un puntaje global alto a partir de sus condiciones y características familiares?

Relevancia para el Usuario

La Secretaría de Educación del Atlántico requiere herramientas que permitan analizar el desempeño estudiantil e identificar factores asociados a mejores resultados académicos. A través de esta pregunta de negocio, la entidad podrá reconocer perfiles de estudiantes con mayor probabilidad de alcanzar altos puntajes en las pruebas Saber 11 y comprender cómo las condiciones familiares pueden influir en el rendimiento académico.

Los resultados obtenidos pueden servir como apoyo para el diseño de estrategias de acompañamiento académico, asignación de recursos educativos y fortalecimiento de políticas orientadas a mejorar la calidad educativa en el departamento.

Análisis de Datos

Para resolver esta pregunta se construyó un modelo de clasificación binaria basado en redes neuronales. La variable objetivo corresponde a si el estudiante obtuvo o no un puntaje global alto en las pruebas Saber 11. Se consideró como estudiante de alto desempeño aquel con un puntaje global igual o superior a 300 puntos. El análisis se enfocó exclusivamente en variables familiares y socioeconómicas del estudiante. Las variables seleccionadas fueron: estrato socioeconómico (fami_estratovivienda), nivel educativo de la madre (fami_educacionmadre), nivel educativo del padre (fami_educacionpadre), número de personas en el hogar (fami_personashogar), número de cuartos en el hogar (fami_cuartoshogar), disponibilidad de automóvil (fami_tieneautomovil) y disponibilidad de lavadora (fami_tienelavadora). Durante la preparación de datos se realizó limpieza de texto, manejo de valores faltantes y normalización de categorías. Posteriormente, las

variables categóricas fueron transformadas mediante One-Hot Encoding para convertirlas en variables numéricas adecuadas para el entrenamiento del modelo.

Modelo Implementado

Inicialmente se implementó un modelo de regresión logística como línea base de comparación. Posteriormente, se entrenó una red neuronal multicapa compuesta por dos capas ocultas con funciones de activación ReLU y una capa de salida sigmoide para clasificación binaria.

Los modelos fueron evaluados mediante métricas de clasificación como Accuracy, Precision, Recall, F1-Score y ROC-AUC. Los resultados muestran que la red neuronal obtuvo un desempeño ligeramente superior a la regresión logística, alcanzando un Accuracy cercano al 85% y un ROC-AUC aproximado de 0.77. Los experimentos fueron documentados utilizando MLflow y el modelo final fue serializado para integrarse posteriormente en un tablero interactivo desarrollado en Dash.

Hallazgos Asociados

Los resultados evidencian que las condiciones familiares y socioeconómicas sí presentan relación con el desempeño académico de los estudiantes en las pruebas Saber 11. Variables como el estrato socioeconómico, el nivel educativo de los padres y las condiciones del hogar mostraron capacidad predictiva sobre la probabilidad de alcanzar un alto desempeño académico.

Además, la comparación entre modelos permitió identificar que la red neuronal logra capturar relaciones más complejas y no lineales entre las variables familiares y el desempeño académico, obteniendo mejores resultados que la regresión logística tradicional

Pregunta de Negocio 3

El puntaje global en las pruebas Saber 11 está influenciado por múltiples dimensiones del estudiante y su entorno, incluyendo condiciones familiares, acceso a recursos tecnológicos y características institucionales del colegio. Por esta razón, además de analizar cada grupo de variables por separado, resulta relevante construir un modelo general que integre estos factores para estimar directamente el puntaje global esperado.

¿En qué medida las condiciones socioeconómicas, el acceso a recursos tecnológicos en el hogar y ciertas características institucionales permiten predecir el puntaje global de los estudiantes del departamento del Atlántico en las pruebas Saber 11?

Relevancia para el Usuario

Para la Secretaría de Educación del Atlántico, esta pregunta es relevante porque permite contar con una estimación aproximada del desempeño académico esperado de los estudiantes a partir de variables disponibles antes de conocer los resultados finales. Esto puede apoyar la identificación de perfiles con mayor riesgo de bajo desempeño y orientar estrategias de acompañamiento académico, fortalecimiento institucional y asignación de recursos. A diferencia de los modelos de clasificación, este modelo estima directamente un puntaje global esperado, lo que permite a la Secretaría de Educación del Atlántico contar con una medida más granular del desempeño académico. Esta estimación facilita identificar no solo si un estudiante se encuentra en riesgo o en alto desempeño, sino también qué tan lejos podría estar de ciertos umbrales relevantes de política educativa, como niveles mínimos esperados o metas institucionales. Además, permite priorizar intervenciones de forma más precisa, comparar perfiles de estudiantes o instituciones y orientar recursos hacia grupos que presenten mayores brechas estimadas en el puntaje global.

Análisis de Datos

El análisis de correlación mostró que los factores más asociados con un mayor puntaje global son la **jornada completa (0.35)**, **tener internet en casa (0.30)**, **tener computador en casa (0.28)**, **madre con educación profesional (0.25)**, **tener automóvil (0.25)**, **padre con educación profesional (0.24)**, **calendario B (0.23)**, **colegio privado (0.21)** y **colegio bilingüe (0.21)**. Esto sugiere que mejores condiciones institucionales, tecnológicas y socioeconómicas se relacionan con mejores resultados académicos.

En contraste, los factores más asociados con menores puntajes fueron la **jornada nocturna (-0.28)**, **no tener internet en casa (-0.27)**, **no tener computador en casa (-0.27)** y **presentar la prueba a mayor edad (-0.21)**. También se observaron asociaciones negativas para **estrato no reportado, madre o padre con primaria incompleta** y **madre con secundaria incompleta**, con valores entre **-0.12** y **-0.14**. Estos resultados ayudan a identificar brechas de desempeño y posibles grupos prioritarios para acompañamiento académico.

Modelo implementado

Se implementaron tres redes neuronales de regresión en Keras para estimar directamente el puntaje global. El Modelo 1 funcionó como línea base con una capa de normalización, una capa densa de 32 neuronas con activación ReLU y una neurona de salida. Luego se evaluó el Modelo 2, con dos capas densas de 64 y 32 neuronas, activación ReLU y Dropout de 0.2. Finalmente, se probó un Modelo 3 con la misma estructura de 64 y 32 neuronas, pero sin Dropout. Todos los modelos fueron entrenados con optimizador Adam, pérdida MSE, métrica MAE y EarlyStopping para controlar el sobreajuste.

Hallazgos Asociados

El Modelo 2 fue seleccionado como modelo final para el tablero, ya que presentó el mejor desempeño relativo frente a las alternativas evaluadas. Aunque la mejora frente al Modelo 1 fue leve, el R^2 aumentó aproximadamente de 0.345 a 0.347, mientras que el Modelo 3 no logró mejorar el desempeño del Modelo 2. Esto indica que el modelo tiene una capacidad predictiva moderada y debe interpretarse como una herramienta de estimación orientativa del puntaje global, útil para identificar perfiles con posibles brechas académicas, pero no como una predicción exacta individual.

Diseño y Desarrollo del Tablero de Datos

Se desarrolló un tablero interactivo en Dash con el objetivo de facilitar la visualización y consulta de los modelos predictivos construidos para el análisis de los resultados Saber 11 en estudiantes del Atlántico. El tablero fue diseñado pensando en la Secretaría de Educación del Atlántico como usuario final, permitiendo una interacción sencilla e intuitiva con los modelos desarrollados.

El tablero integra tres modelos predictivos diferentes, organizados en pestañas independientes. Cada pestaña corresponde a una pregunta de negocio específica y permite ingresar características del estudiante o de la institución educativa para obtener predicciones en tiempo real.

La primera sección corresponde al modelo familiar, enfocado en predecir la probabilidad de que un estudiante alcance un alto desempeño académico a partir de variables socioeconómicas y familiares. El usuario puede seleccionar características como estrato socioeconómico, nivel educativo de los padres, número de personas en el hogar y condiciones generales de vivienda. El resultado se presenta mediante un indicador visual tipo gauge que muestra la probabilidad estimada de alto desempeño.

La segunda sección corresponde al modelo institucional o de colegio, el cual también fue planteado como un problema de clasificación binaria. Este modelo busca predecir si un estudiante alcanzará o no un puntaje global alto en las pruebas Saber 11 utilizando variables relacionadas con la institución educativa, como jornada, naturaleza del colegio, calendario académico, ubicación y condición bilingüe.

A diferencia del modelo familiar, este enfoque se centra en analizar cómo las características institucionales pueden influir en el desempeño académico de los estudiantes. El resultado del modelo se presenta mediante indicadores visuales y probabilidades asociadas al alto desempeño académico.

La tercera sección corresponde al modelo general, desarrollado como un modelo de regresión para estimar directamente el puntaje global esperado del estudiante. Este modelo combina variables familiares, tecnológicas e institucionales para generar una predicción numérica del resultado en las pruebas Saber 11.

Finalmente, el tablero incorpora una pestaña de comparación de modelos, donde se presentan de forma consolidada las métricas obtenidas por cada uno de los modelos desarrollados. Esta sección permite comparar visualmente el desempeño de los modelos de clasificación y regresión mediante indicadores como Accuracy, Precision, Recall, F1-Score, ROC-AUC, RMSE, MAE y R^2 . Además, se incluyen gráficos comparativos que facilitan la interpretación de resultados y permiten identificar cuál modelo presenta mejor capacidad predictiva según el tipo de problema abordado. Esta funcionalidad brinda a la Secretaría de Educación del Atlántico una herramienta adicional para analizar la calidad y comportamiento de los modelos implementados.

Despliegue y Mantenimiento de Datos

El tablero final fue desplegado en la nube utilizando **AWS** y **contenedores Docker**, de acuerdo con el requisito de la Tarea 7. La aplicación fue desarrollada en **Dash** y empaquetada en una imagen Docker construida a partir del archivo Dockerfile del proyecto. Para el despliegue se utilizó una instancia en AWS con sistema operativo Ubuntu, a la cual se accedió mediante SSH. En esta instancia se instaló Docker, se clonó el repositorio del proyecto, se construyó la imagen del tablero y se ejecutó el contenedor exponiendo el puerto configurado para que la aplicación quedara accesible desde una URL pública.

La estructura del proyecto permite que el tablero funcione de manera independiente al ambiente local de desarrollo. El código principal del tablero se encuentra en Tarea 5 - Dash/app.py, las dependencias necesarias están definidas en requirements.txt, los datos procesados se encuentran en Tarea 2 - Limpieza_Datos/saber11_limpio.csv y los modelos entrenados están almacenados en la carpeta models/. Esta organización facilita el mantenimiento del producto, ya que cualquier actualización del código, los datos o los modelos puede gestionarse desde el repositorio y posteriormente sincronizarse en la instancia de AWS.

Los modelos desplegados se encuentran **serializados en archivos locales**, cumpliendo con el requisito de que el tablero no entrene modelos al ejecutarse. En particular, el modelo general de regresión se guarda como modelo_general_regresion.h5, junto con columnas_general_encoded.pkl, que conserva el orden de las variables utilizadas durante el entrenamiento. De forma similar, los modelos de clasificación familiar y de colegio también se almacenan como archivos preentrenados dentro de la carpeta models/. Al iniciar el tablero, la aplicación carga estos archivos directamente desde el contenedor y los utiliza para generar predicciones en tiempo real.

El mantenimiento del despliegue se realiza mediante un flujo reproducible. Primero, los cambios se actualizan en el repositorio de GitHub. Luego, en la instancia de AWS, se sincroniza el proyecto con git pull o se copian los archivos actualizados. Después se reconstruye la imagen Docker y se reinicia el contenedor para reflejar los cambios en la aplicación. Este flujo permite actualizar modelos, corregir errores o modificar el tablero sin cambiar manualmente el ambiente de ejecución. Como evidencia del despliegue, se incluyen capturas de pantalla de la instancia AWS, la terminal con Docker, la construcción de la imagen, la ejecución del contenedor, la carga de los modelos serializados y la URL pública del tablero en funcionamiento en la carpeta “Tarea 6/Despliegue”.